

PLAYBOOK DE TRANSFORMACIÓN DIGITAL Y ANALÍTICA DE RIESGOS BANCARIOS

Guía Metodológica y Tecnológica para la Implementación de Modelos de Decisión en Tiempo Real y Gobernanza de IA

PREPARADO PARA: Dirección de Riesgos, Analítica y TI

DOCUMENTO: Playbook de Transformación Digital

VERSIÓN: 1.0 (Producción)

FECHA DE EMISIÓN: Q1 2024

Módulo 1: Gobierno y Modelo Operativo (El Data & AI CoE para Riesgos)

1. Introducción y Filosofía "Risk for Business" (R4B)

La transformación digital de un departamento de riesgos bancarios requiere un cambio de paradigma organizativo. Se debe transicionar de una estructura de silos tradicionales (donde Riesgo actúa como una entidad puramente de control y auditoría posterior) hacia un enfoque de **Risk for Business (R4B)** y un modelo de **Agile@Scale**. El objetivo primordial es habilitar la velocidad del negocio y optimizar la conversión comercial en canales digitales sin sacrificar la rigurosidad ni incrementar los niveles de pérdida esperada.

2. Estructura de Tribus y Células Ágiles (Hub-and-Spoke)

Se implementará un modelo operativo híbrido conocido como **Hub-and-Spoke**, que distribuye el talento técnico mientras mantiene una gobernanza y unos estándares metodológicos unificados desde el centro.

- **El Hub (Data & AI CoE):** Formado por los "Chapters" (Capítulos) o disciplinas técnicas. Es el encargado de definir las herramientas transversales, metodologías de modelado, estándares de MLOps, plataformas de datos y la gobernanza del modelo de riesgos (2LoD - Segunda Línea de Defensa).
- **Los Spokes (Risk for Business Squads):** Células ágiles multidisciplinarias incrustadas de forma dedicada en cada línea de negocio (Adquisición de Tarjetas, Préstamos de Consumo, PYMEs, etc.). Estas células operan de forma autónoma bajo la filosofía de la Primera Línea de Defensa (1LoD).

3. Matriz de Roles y Responsabilidades en el Squad de Riesgo Ágil

Para que un escuadrón funcione con velocidad y autonomía, debe contar con perfiles específicos y complementarios:

Rol	Descripción y Responsabilidades
Product Owner (Riesgo/Negocio)	Define la visión del producto crediticio, prioriza el backlog basándose en el valor neto del negocio y gestiona la relación entre las metas comerciales de colocación y el apetito de riesgo regulatorio.
Analytics Translator	Rol crítico de enlace. Traduce las necesidades de negocio en requerimientos técnicos analíticos para los científicos de datos, y explica el impacto de las métricas de los modelos (ej. Gini, KS) en el P&L y la experiencia de usuario (funnel) al Product Owner y partes interesadas.
Lead Data Scientist (Risk)	Diseña y desarrolla los modelos predictivos de riesgo de crédito (PD, LGD, EAD, Fraude) garantizando el rigor estadístico, la consistencia de las variables y la robustez metodológica.
Data Engineer (Riesgo)	Construye e instrumenta los pipelines de datos (ETL/ELT), gestiona la ingesta de datos en tiempo real y el mantenimiento operativo del Feature Store centralizado.
MLOps Engineer	Automatiza el ciclo de vida de los modelos predictivos, el despliegue de APIs, el control de versiones e implementa la infraestructura de monitoreo del rendimiento y "drift" (deriva) en producción.
Risk Policy Analyst (Riesgo Tradicional)	Aporta el conocimiento profundo de la regulación local (superintendencias), políticas internas del banco, define las reglas duras (knock-outs) e interactúa con el equipo de control de cumplimiento y auditoría.

4. Ceremonias y Gobierno de Toma de Decisiones

- **Quarterly Business Reviews (QBR):** Sesión trimestral donde la dirección de Riesgos (CRO), Negocio y Finanzas calibran colectivamente el Appetite de Riesgo, actualizan las metas de pérdida esperada y definen los OKRs para los Squads de colocación.
- **Risk Watchtower (Torre de Control):** Flujo de trabajo continuo y automatizado integrado en herramientas como Jira/Confluence. Permite evaluar y aprobar de manera ágil los cambios en las políticas y lanzamientos del Front-End sin requerir comités burocráticos semanales, mediante validación por checklist automatizado.

Módulo 2: Estrategia y Arquitectura de Datos

1. Visión General de la Arquitectura de Datos

El éxito de un modelo predictivo de riesgo en producción depende críticamente de la consistencia y la velocidad de los datos de entrada. No es viable ejecutar decisiones de crédito instantáneas (Straight-Through Processing - STP) si los datos se procesan con un retraso de 24 horas (Batch T+1). Se propone una arquitectura de datos moderna de tipo **Lakehouse** que soporte analítica batch e ingesta en tiempo real en un entorno unificado y gobernado.

2. Flujo de Datos E2E (End-to-End)

El flujo arquitectónico se estructura en tres capas principales:

- **Ingesta por Lotes (Batch):** Extrae diariamente información estática e histórica del Core Bancario, saldos de cuentas de ahorro/corriente, estados de pago de créditos anteriores, información catastral y datos demográficos del cliente.
- **Ingesta en Tiempo Real (Streaming):** Captura en tiempo real a través de colas de mensajería (como Apache Kafka, AWS Kinesis o GCP Pub/Sub) los eventos de comportamiento digital del cliente en la Web o App móvil, geolocalización, metadatos del dispositivo, velocidad de digitación (proxy de fraude) y datos transaccionales del día.
- **Data Lakehouse (Capa de Almacenamiento y Procesamiento):** Utilización de plataformas modernas (como Databricks o Snowflake) que combinan la flexibilidad y bajo costo del almacenamiento de datos no estructurados de un Data Lake con el rendimiento, control transaccional ACID y seguridad de un Data Warehouse tradicional.
- **El Feature Store Centralizado (Elemento Crítico):** El Feature Store es el componente de infraestructura que elimina el principal punto de fricción en los proyectos de IA en banca: el Train-Serve Skew (desviación entre entrenamiento y servicio). Consiste en un Offline Feature Store (para entrenamiento) y un Online Feature Store en memoria de baja latencia (Redis) para servir las variables al modelo en menos de 100 milisegundos.

3. Decisiones Tecnológicas y Cumplimiento Regulatorio (BCBS 239)

- **Despliegue de Nube frente a On-Premises:** Dependiendo de las restricciones de la superintendencia financiera local con respecto a la protección de datos personales (PII) e información financiera confidencial, se definirá si el motor analítico se implementa en nube pública, nube híbrida o nube privada local de alta seguridad.
- **Linaje de Datos y Gobernanza:** Para cumplir con el estándar internacional de gobernanza de datos de riesgo **BCBS 239**, es obligatorio implementar catálogos de datos corporativos (como Collibra, Alation o Apache Atlas) para documentar el origen exacto, las transformaciones lógicas y los destinos de cada variable analizada para otorgar un crédito.

Módulo 3: Modelado Analítico y de IA (Técnicas, Métricas y Evaluación)

1. Transición de Modelos Tradicionales a Inteligencia Artificial

La modernización del análisis de riesgo no descarta la rigurosidad estadística tradicional, sino que la potencia mediante algoritmos de Machine Learning capaces de procesar relaciones no lineales y grandes volúmenes de datos transaccionales y alternativos.

- **Probabilidad de Default (PD):** Evolución de Regresión Logística (Scorecards tradicionales) a **XGBoost, LightGBM**, y Redes Neuronales Profundas. Permite un mayor poder discriminativo de riesgo (incremento del Gini), reduciendo los falsos rechazos en la base del funnel.
- **Pérdida en Caso de Default (LGD):** Evolución de tablas estáticas e históricas por colateral a modelos de regresión de ensamble (Random Forest, Gradient Boosting), permitiendo una estimación precisa y dinámica del capital regulatorio y optimización de las provisiones bajo norma IFRS 9.
- **Modelos de Prevención de Fraude:** Evolución de reglas manuales estáticas en base de datos a modelos de aprendizaje no supervisado (Detección de anomalías, Isolation Forests) y Analítica de Grafos para la mitigación instantánea de fraudes de identidad (suplantación) en canales digitales.

2. Algoritmos Recomendados: El Estándar XGBoost y LightGBM

Para el modelado de riesgo de crédito en banca de consumo, los modelos de Gradient Boosting basados en árboles de decisión (**XGBoost y LightGBM**) son los líderes indiscutibles. Ventajas técnicas clave:

- Manejo nativo y eficiente de datos faltantes (missing values).
- Robustez ante la multicolinealidad de las variables financieras.
- Capacidad de capturar interacciones complejas de variables sin necesidad de ingeniería manual extrema de atributos.

3. El Requisito de la Inteligencia Artificial Explicable (XAI)

Un modelo "caja negra" puro no puede ponerse en producción en un banco debido a que los entes reguladores y el departamento de auditoría exigen transparencia total sobre las razones de denegación de un crédito. Para solucionar esto se aplican dos metodologías obligatorias:

1. **Monotonicity Constraints (Restricciones de Monotonidad):** Se fuerza matemáticamente al algoritmo XGBoost a mantener una relación lógica de negocio con variables clave. Ej: a mayor nivel de endeudamiento documentado, la probabilidad de default estimada del modelo debe obligatoriamente aumentar.

2. **SHAP (SHapley Additive exPlanations):** Técnica de teoría de juegos cooperativos que desglosa con total precisión la contribución individual de cada variable al score final de un cliente específico. Esto permite automatizar los motivos específicos de rechazo exigidos por la ley de derechos del consumidor financiero (ej: "Se rechazó el crédito debido a: 1. Incremento de deuda externa en buró en 35%, 2. Caída del saldo promedio en cuenta de ahorros en un 50%").

4. Framework de Evaluación y Validación (Model Risk Management)

Antes de que un modelo sea aprobado para producción por la Segunda Línea de Defensa (2LoD), debe superar un riguroso set de métricas de validación:

Métrica	Descripción y Estándar de Aceptación
Coeficiente de Gini / Curva ROC	Mide la capacidad de ordenamiento y discriminación del modelo para separar buenos de malos clientes. Se exige un uplift mínimo de +5 a +10 puntos de Gini en los modelos Challenger (ML) comparados con los modelos Champion (Regresión Logística actual).
Estadístico KS (Kolmogorov-Smirnov)	Mide la distancia máxima entre las funciones de distribución acumulada de clientes pagadores e impagadores. Una métrica de KS > 40% es el estándar mínimo de aceptación en la industria para consumo.
PSI (Population Stability Index)	Evalúa si la distribución de las variables y el score de la población actual en producción han variado con respecto a la población con la que se entrenó originalmente el modelo. • PSI < 0.1: Estabilidad. • 0.1 a 0.25: Requiere monitoreo. • > 0.25: Deriva severa ('Model Drift'), requiere reentrenamiento de emergencia.

Módulo 4: Motor de Decisiones e Integración con el Negocio (Funnel y Reglas)

1. El Motor de Decisiones de Riesgo (Risk Decision Engine - RDE)

El Motor de Decisiones es el componente de software central que recibe las solicitudes de crédito del Front-End (App, Web, Sucursal), orquesta las llamadas a servicios externos e internos, corre los modelos predictivos de Machine Learning y aplica las reglas lógicas de negocio para emitir una oferta final en milisegundos.

2. Cascada Analítica de Decisiones en Tiempo Real (Flujo Secuencial)

Para optimizar los recursos computacionales y evitar incurrir en costos elevados por consultas innecesarias a burós de crédito externos, el RDE estructura el funnel de decisión en cuatro capas consecutivas:

1. **Capa 1: Reglas Duras / Filtros de Exclusión (Knock-out Rules):** Reglas de política binarias y estáticas que se ejecutan al inicio de la cadena. Filtros de edad mínima/máxima, presencia en listas AML (lavado de activos), o moras graves vigentes mayores a 90 días en centrales de riesgo.
2. **Capa 2: Validación de Identidad y Fraude (Digital Profiling):** Evaluación en tiempo real del riesgo de suplantación mediante biometría facial pasiva (Liveness Test) y comparación con bases de datos gubernamentales de identificación, cruzado con el perfil de riesgo del dispositivo móvil.
3. **Capa 3: Consulta Externa y Ejecución del Scoring (PD):** Se realiza el llamado vía API para consultar el historial en el buró de crédito externo, jala las variables analíticas calculadas en el Feature Store interno y procesa el modelo XGBoost de Probabilidad de Default (PD). El resultado clasifica al cliente en un Risk Tier de la A a la E.
4. **Capa 4: Capacidad de Pago y Pricing Dinámico:**
 - **Cálculo del PTI (Payment-to-Income):** Se calcula el ingreso neto disponible del cliente y, según su Risk Tier, se aplica un porcentaje límite de endeudamiento (ej. 40% para Tier A, 15% para Tier D) para determinar la Cuota Mensual Máxima.
 - **Monto Máximo Dinámico:** Aplicando valor presente en base a la Cuota Máxima, plazo y tasa asignada, se calcula el Monto Máximo de Crédito a pre-aprobar.
 - **Pricing Basado en Riesgo (Risk-Based Pricing):** Se asigna la tasa de interés (APR) según la banda de riesgo del cliente, donde la tasa cubre el costo de fondeo, costos operativos, costo de capital y la pérdida esperada ($PD \times LGD$).

3. Estrategia de Fricción Dinámica (Dynamic Friction) en el Funnel Digital

La experiencia del cliente en la aplicación se adapta en tiempo real según el nivel de riesgo determinado por el RDE:

- **Flujo Sin Fricción (Straight-Through Processing - STP):** Clientes clasificados en Tier A o B son aprobados instantáneamente en menos de 3 segundos sin requerir la carga manual de ningún documento.
- **Flujo con Fricción Útil (Step-up Verification):** Clientes clasificados en Tier C o D experimentan pasos adicionales dinámicos, tales como validación biométrica facial avanzada, o la solicitud de conectar su cuenta de nómina mediante Open Banking para validar sus ingresos de forma inmediata.

Módulo 5: MLOps y Operaciones Continuas (Mantenimiento del Ciclo de Vida)

1. Importancia del MLOps en Riesgos

La dinámica del comportamiento del consumidor financiero cambia con rapidez debido a factores macroeconómicos, inflación o cambios regulatorios. Los modelos predictivos tienden a degradarse naturalmente con el tiempo. El marco de **MLOps (Machine Learning Operations)** proporciona los procesos y la infraestructura tecnológica para garantizar que los modelos de riesgos operen de manera segura, escalable y controlada en producción.

2. El Pipeline de Integración y Despliegue Continuo (CI/CD/CT)

Para eliminar el tiempo de demerito tradicional de meses para desplegar un modelo analítico, el CoE implementa pipelines automatizados:

- **Continuous Integration (CI):** Automatiza las pruebas unitarias del código del modelo, la validación de consistencia de tipos de datos y la reproducibilidad matemática de las variables del Feature Store.
- **Continuous Deployment (CD):** Despliega el modelo empaquetado en contenedores ligeros (como Docker en Kubernetes) expuestos como microservicios de API de alta disponibilidad que interactúan directamente con el RDE.
- **Continuous Testing & Validation (CT):** Permite correr experimentos controlados en producción de forma paralela (pruebas A/B o Champion-Challenger), donde el 90% de las decisiones de crédito se toman con el modelo oficial (Champion) y un 10% se desvía en la sombra hacia el nuevo modelo candidato (Challenger) para evaluar su rendimiento predictivo con datos reales antes de un reemplazo definitivo.

3. Monitoreo Automatizado de Deriva y "Early Warning"

El sistema de MLOps debe generar tableros de control en tiempo real (ej. usando Grafana o Kibana) y alertas automáticas para los Chapters de validación de modelos ante anomalías:

- **Monitoreo del Input (Data Drift):** Si el porcentaje de solicitudes de clientes de baja gama de ingresos se incrementa súbitamente un 30% en una semana debido a una campaña comercial masiva, el sistema emite una alerta de data drift.
- **Monitoreo del Output (Model Drift - PSI):** Evaluación semanal de la estabilidad poblacional de los Scores. Si el PSI cruza el umbral de 0.25, el pipeline dispara un proceso de reentrenamiento automático del modelo con los datos transaccionales del último mes.
- **Monitoreo de Calidad de Datos:** Vigilancia continua para verificar la latencia de respuesta del Feature Store online y asegurar que el porcentaje de valores nulos o vacíos en las variables que

alimentan al modelo se mantenga por debajo del 1% del volumen total de transacciones.